

# 基于动态 Token 向量维度扩张的自适应可解释 Transformer 模型

张京鹏

2026 年 2 月 28 日

## 摘要

本文是我在了解传统的 Transformer 架构后，针对其“黑箱”的痛点，尝试提出的一种微调后可解释的 Transformer 模型的理论架构：

传统的 Transformer 模型的 Embedding Matrix 是固定维数的线性空间，无论新增多少语义都必须挤在预先设定的高维空间里。这种“叠加原理”导致特征高度耦合，也就是我们常说的“黑盒”。

笔者认为，不可解释的根源在于维数固定导致的特征抽象。在旧架构中，所有维数在训练开始就固定了，这不符合人类由浅入深、由点及面的认知直觉。我希望能对 Transformer 进行微调：变固定维数为自适应扩张维数。当模型遇到新语义却“挤不进”现有维度时，自动开辟新维度，从而让新维度与新输入语义建立明确的因果联系，增强可解释性。

## 1 理论框架

### 1.1 名词介绍

- **自适应维数 Token 向量**：不再是固定长度，而是可以随训练进程“长”出新维度的向量。
- **观测窗口  $M$  (Memory Window)**：
  1. 作为信号判定的统计周期（看这段时间模型有没有进步）。
  2. 作为可解释性的溯源跨度（新维度就是为了解决这  $M$  步里无法拟合的新语义）。
- **惩罚系数  $\lambda$** ：用来压制模型盲目扩张，只有当新维度带来的收益足够大时，才允许“生长”。

### 1.2 运行机制

#### 第一步：监控“认知瓶颈”信号

模型从低维开始生长。由于空间有限，训练一段时间后会因为“语义挤压”进入瓶颈期。

触发条件示例：模型训练  $M$  轮后，损失函数 (Loss) 下降幅度不足 0.1%。此时判定模型“学不动了”，发出扩容信号。

## 第二步：触发“维数扩张”机制

笔者引入包含维度成本的损失函数：

$$\mathcal{L} = \text{MAE} + \lambda D \quad (1)$$

其中  $D$  是向量维数。判定逻辑：

1. 触发信号后，模型回滚  $M$  轮。
2. 增加一个新维度，专门对这  $M$  轮产生的残差（拟合不掉的部分）进行训练。
3. 重新计算  $\mathcal{L}$ 。如果 MAE 的下降值大于预设参数  $\lambda$ ，判定扩张成功，继续向下训练。

## 第三步：事后解释

由于新维度是专门为了搞定“原来拟合不了的语义”而开辟的，我们就可以建立该维度与新输入语义的对应关系。

### 1.3 流程演示（以二维到三维为例）




图 1: 维度扩张运行机制流程图

**第一步** 高矮，胖瘦的语义向量是正交的，完美隔离。

**第二步** 输入新语义（男女）。由于二维线性空间太小，无法让不同语义正交，出现语义挤压（表现为损失函数下降缓慢）。于是释放信号，要求增加维数。

**第三步** 回滚与重练。模型精准回滚到  $M$  步之前，新开一个维度。这个新维专门负责训练之前拟合不掉的“残差”信息。

**第四步** 对应与解释。训练完成后，新维度完美承载了“男女”语义。此时，新维度与这  $M$  轮输入的新语义形成了明确的对应关系，增强了可解释性。

## 2 实验设计

1. **初始训练**：先用特定语料（如数学逻辑）训练一个极低维的小模型。
2. **引入新语料**：突然输入完全不同领域的语料（如法律条文）。观察到由于空间饱和，损失函数进入平台期。
3. **动态扩张**：执行回滚，开辟新维度拟合残差。
4. **因果验证**：观察损失函数是否显著下降（对比  $\lambda$ ）。
5. **权重对齐**：如果发现每次输入法律语料时，该“新维度”的权重显著激增，即可证明：这个维度  $\approx$  法律语义。

## 3 局限性分析

虽然这种方法在当下为特定语义保留了专属维度，但如何保证在后续漫长的海量数据训练中，这些维度不会因为参数漂移而再次变得模糊，仍是未来需要攻克的难点。